基于RAG的多模态历史问答Agent

课题目标与重点

本课题围绕多模态大模型与 RAG（检索增强生成）技术展开，要求设计并实现一个面向历史问答场景的智能问答系统。

系统需要能够：

- 理解用户输入的历史问题；
- 结合外部历史知识库进行信息检索；
- 基于检索结果生成较为准确的历史问答内容；
- 在指定历史问答数据集上完成测试与评估。

课题重点包括：

- 多模态大模型的使用；
- RAG 检索流程设计；
- 问答 Agent 的组织与实现；
- 历史问答任务的评测与分析。

基础知识要求

为了顺利完成本课题，建议具备以下基础：

编程基础

- 熟悉 Python 编程；
- 能够阅读并修改已有代码。

相关知识

- 了解自然语言处理（NLP）与计算机视觉（CV）的基本概念；
- 对大语言模型（LLM）有基本了解，知道 Prompt 的基本使用方式；
- 了解 Embedding、向量检索等基础概念。

工具使用

- 熟悉 PyTorch 的基本使用；

- 了解 Hugging Face Transformers、vLLM 等推理框架；
- 接触过 LangChain、LlamaIndex 等框架更佳，但不是必须要求。

技术方案

本课题基于指定的大模型与统一提供的检索服务，完成一个面向历史问答场景的多模态 RAG 系统。

基座模型

统一使用 Qwen2.5-7B -VL 作为基础模型，用于多模态理解与问答生成。

系统整体流程

系统整体流程主要包括以下几个部分：

1. 问题输入与理解

系统接收用户输入的问题，输入形式可以包括：

- 文本；
- 图片；
- 文本与图片混合输入。

模型需要对问题内容进行理解，并结合图片信息完成后续问答。

2. 历史知识检索

系统需要根据用户问题，调用平台提供的历史知识检索接口，从历史知识库中获取相关背景资料。

检索服务通过 HTTP API 提供，平台已完成历史知识库整理、检索索引构建以及检索服务部署。

接口返回内容可能包括：

- 历史文本片段；
- 相关图片；
- 史料描述；
- 来源信息等。

同学们可以围绕：

- Retrieval 策略；
- 多轮检索；
- Rerank；
- 检索结果筛选与组织等方向进行优化。

3. 上下文组织

系统需要将检索得到的历史资料与用户问题进行整合，构造适合模型生成的输入内容。

重点包括：

- Prompt 设计；
- 多模态上下文组织；
- 长上下文处理；
- 无关信息过滤等。

4. 回答生成

利用 Qwen2.5-VL 基于检索得到的信息生成最终历史问答结果。

需要尽量减少：

- 历史事实错误；
- 幻觉内容；
- 与问题无关的生成结果。

鼓励尝试的优化方向

同学们可以围绕以下方向进行优化：

- Retrieval；
- Rerank；
- Prompt 优化。

研究 / 实践目标与预期成果

目标

实现一个搭载rag完整链路并且能够稳定运行的多模态历史问答 Agent，并在指定评测任务上取得较好的效果。

需要提交的内容

1. 完整项目代码（含依赖说明与运行方式）；
2. 简要技术报告，说明系统设计与优化思路；
3. （可选）简单的交互界面或演示 Demo。

提供的资源

为了降低部分复杂的工程工作，平台将提供以下内容：

1. 指定模型
   提供统一的 Qwen2.5-7B-VL 模型。
2. 检索接口

平台将提供：

- API 调用文档；
- 示例代码；
- 基础调用 Demo；

为便于接口管理与调用统计，每位同学将获得对应的 API Key（可使用学号作为身份标识）。

3. 评测工具
   提供本地评测脚本与部分测试样例，用于调试与效果验证。

环境与考核方式

实验环境

支持 Linux、Windows 与 MacOS。

如需本地运行 Qwen2.5-7B-VL，建议使用具有 16GB 以上显存的 GPU。

考核内容

1. 系统完整性（50%）

- 能够正常运行；
- 具备完整的检索与生成流程；
- 代码结构清晰。

2. 问答效果（20%）

- 根据隐藏测试集上的评测结果进行评分；
- 重点考察相较于 Baseline 的效果提升。

3. 方法设计（20%）

- 是否对检索、Prompt 或上下文组织进行了改进；
- 改进是否对最终效果有帮助。

4. 工程与文档（10%）

- 代码规范与注释情况；
- 技术报告的完整性与清晰度。