基于RAG的多模态历史问答Agent项目说明

整体介绍

介绍课题

本课题要求学生基于 Qwen2.5-VL-7B-Instruct 和 DashVector 向量知识库，实现一个**面向历史问答任务能够自动完成问答执行流程的多模态 RAG Agent**。核心重点是让学生设计并优化这条 RAG Agent 流程，使模型能够借助外部历史知识库给出更准确、更稳定的问答结果。

链路拆解

整个系统可以理解为一条完整的问答链路：



基于这条链路，我们会提供**统一的模型权重、基础运行环境、向量库访问配置和50题公开测试样例，**算力资源上是**每人2张h200**。学生的主要任务是在给定资源的基础上完成并优化 RAG 问答流程。

评分

1. 最终提交时，学生需要提交**可以运行的完整代码**。我们会在统一环境中使用**隐藏的 1000 题**测试集运行学生代码，检查其是否完成了 RAG 流程，并统计最终问答准确率。评分时会先参考我们提前评测好的 baseline：如果学生系统**相较 baseline 有有效提升**，可以获得**30%基础分**；在此基础上，再根据隐藏测试集上的**准确率排名分配剩余效果分**。
2. **检索、推理时长，方法创新**等都会作为老师考核的标准。

细节介绍

1 相关文件路径

1. 模型权重路径
   a. 基础模型：/inspire/qb-ilm2/project/26summer-camp-16/public/Rag_Based_HistAgent/Models/qwen2.5-VL-7B-Instruct
   b. embedding模型：/inspire/qb-ilm2/project/26summer-camp-16/public/Rag_Based_HistAgent/Models/gem-Qwen2-VL-7B-Instruct
2. 项目骨架文件夹

/inspire/qb-ilm2/project/26summer-camp-16/public/Rag_Based_HistAgent/student_package

2 开发形式说明

1. 个人开发形式：public文件夹只做读取，大家的开发在个人工作目录下。即将student_package复制到自己的工作目录下开发。
2. 合作开发形式：因为启智平台无法联网且public文件夹是所有人共享的，而个人开发目录是仅自己可见，建议合作开发可以把相关代码下载到本地，自行采取组内代码共享方案。（git or .....）

3 开发内容说明

1. 每个小组维护一个solution文件夹，并且以solution/main.py为唯一入口
2. 需要输出一份time_cost.jsonl （因为每组的实现策略不同，这个时间自己统计输出）

```
代码块
1   {"index": xxx, "retrieval_cost": "5s", "infer_cost": "0.2s"}
```

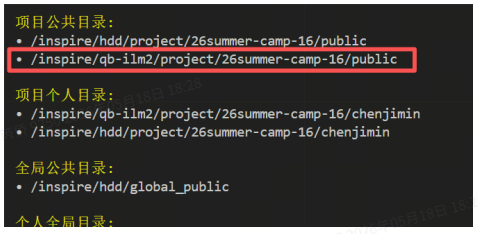


Figure 1 Public文件夹选取

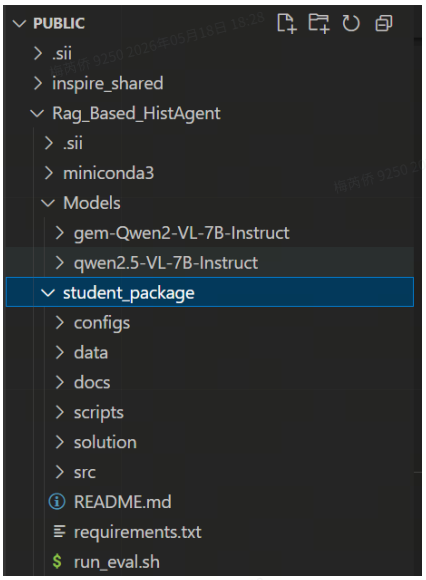


Figure 2 Public文件夹路径

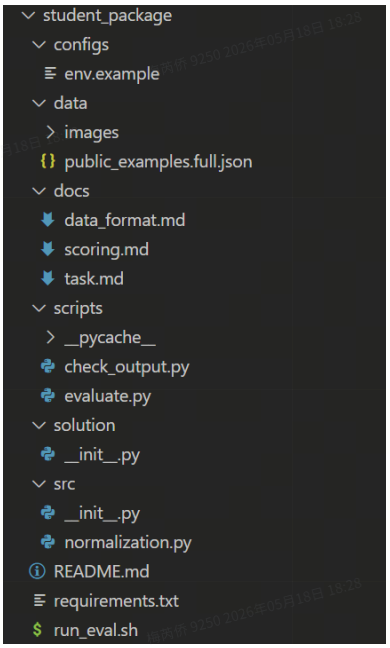


Figure 3 student_package文件结构

4 测试集

1. 公开测试集位于student_package/data文件夹下，供给同学们自行开发测试
2. 评分在非公开测试集上测试，计算得分

5 小组提交内容说明

1. solution文件夹压缩包
2. Technical Report文档（word、txt、md、arxiv.....）
3. 小组汇报PPT
    a. 方法设计
    b. 组内分工
    c. .....